

Proyecto

Sistema de Apoyo a la Toma de Decisiones

10 de diciembre de 2025

Perrito Reciclado - Sistema predictivo para clientes frecuentes



Integrantes del equipo

- Gutierrez Nolazco Adolfo
- Rodriguez Callejas Axel Jared
- Serrano Esparza David
- Tolentino Hernandez Aldo Jared

Índice

Perrito Reciclado - Sistema predictivo para clientes frecuentes	1
Índice	2
Introducción	3
Introducción Perrito Reciclado	4
Introducción ¿Qué decisión se busca optimizar o definir?	5
Introducción Objetivos generales y específicos.	6
Marco Teórico	7
Marco Teórico Definición y explicación de los conceptos centrales	7
Sistemas de Apoyo a la Toma de Decisiones (SATD/DSS)	7
Arquitectura de un DSS	8
Tipos de DSS	8
Tipos de Modelos en Análisis de datos	8
Modelos Descriptivos (El espejo retrovisor)	9
Modelos Predictivos (La bola de cristal)	9
Modelos Prescriptivos (El GPS inteligente)	10
Gestión de Relaciones con el Cliente (CRM) y Principio de Pareto	11
Árboles de Decisión	11
Sobreajuste (Overfitting) en Modelos Predictivos	12
One-Hot Encoding	12
Matriz de Confusión	13
Métricas de Evaluación para Clasificadores	13
Inteligencia Artificial (IA) y Machine Learning en el contexto de SATD	14
Metodología CRISP-DM	14
Investigación aplicada	15
Programación Literaria	15
Marco Teórico Descripción y Justificación de la Herramienta Utilizada	16
Estado del arte	20
Estado del Arte Minería de Datos para PyMEs	20
Estado del Arte Predicción de Fuga de Clientes	21
Estado del Arte Segmentación y perfilado de Clientes	21
Metodología	22
Metodología Fase 1: Comprensión del Negocio.	22
Metodología Fase 2: Comprensión de los Datos	22
Metodología Fase 3: Preparación de los Datos	23
Metodología Fase 4: Modelado (Modeling)	24
Metodología Fase 5: Evaluación	24
Metodología Fase 6: Despliegue	25
Desarrollo	26
Desarrollo Análisis del Proceso y Selección de Características	26

Desarrollo Análisis del Proceso y Selección de Características	26
Desarrollo Modelado y Evaluación	27
Desarrollo Interfaces Desarrolladas	28
Interfaz de Entrada de Datos (Input)	28
Interfaz de Salida y Resultados (Output)	29
Desarrollo Impacto en la Decisión	30
Reducción de la Incertidumbre Operativa	30
Optimización del Presupuesto de Marketing	30
Personalización de la Estrategia	30
Conclusiones	31
Principales logros	31
Verificación del cumplimiento de los objetivos	31
Limitaciones del Modelo y del Proyecto	32
Trabajo Futuro (Mejoras y Extensiones)	32
Anexos	33
Código utilizado	33
Capturas de pantalla adicionales de la herramienta de modelado	37
Fuente de los datos	38
Referencias APA	38

Introducción

En un mundo cada vez más digitalizado, la transformación digital ha forzado la migración o creación de **sistemas diseñados para ayudar a los directivos y profesionales de diversas áreas en la toma de decisiones**, especialmente en situaciones donde existe incertidumbre o donde el problema no está totalmente estructurado.

Dicho sistemas reciben el nombre de **DSS** (por sus siglas en inglés: **Decision Support System**) o su nombre en español “**Sistemas de Apoyo a la Toma de Decisiones**”, centrados no en una automatización total de la toma de decisiones, si no en proporcionar una **serie de herramientas que faciliten que un ser humano tome la mejor decisión posible** basándose en hechos y proyecciones.

El proyecto se centra en el desarrollo de un Modelo de Decisión Inteligente (DSS) para una empresa del sector de productos sostenibles para mascotas, ubicada en la capital del estado de Veracruz (Xalapa) y teniendo presencia en varias localidades del estado como lo son: Xalapa, Coatepec y el Puerto de Veracruz.

La premisa o **idea fundamental es utilizar el histórico de datos de la organización diseñado y proporcionado en distintos formatos** (Como Excel, SQL o PowerBI) que incluye perfiles de clientes, ganancias, ventas e inventarios **para construir un sistema con un enfoque mixto (predictivo y descriptivo)** enfocado en un proceso, en nuestro caso **enfocado en el apartado de clientes**, el sistema será capaz de analizar, predecir y clasificar a los clientes tanto actuales como potenciales en categorías de lealtad y así sugerir acciones predeterminadas.

Por ejemplo, si el modelo predice una baja probabilidad de lealtad para un cliente en Coatepec, **el sistema prescribirá estrategias definidas para tratar de retenerlo**, como: "Ofrecer envío gratuito" o "Descuento de bienvenida".

El desarrollo de este proyecto contempla desde la contextualización del mismo, el detallado de la organización, objetivos y el contexto del problema, un paso por el desarrollo de un marco teórico, estado del arte, la metodología utilizada durante la elaboración del susodicho hasta el diseño, creación y modelado del sistema DSS final con interfaz de usuario como producto final y una conclusión y anexos del proyecto realizado.

Introducción | Perrito Reciclado

Perrito reciclado es una empresa de origen Xalapeño fundada en el 2020 por dos Xalapeñas con amor hacia los animales y al medio ambiente, enfocados en la creación de productos ecológicos diseñados para mascotas, como perros y gatos.

Actualmente, **poseen presencia** con su sede física en Xalapa, además distribuyen sus productos en vía web en 3 localidades de Veracruz como lo son **Xalapa, Coatepec y Veracruz**, dicho canal web es el que les da mayor presencia en cuanto a ventas e inventario.

En el año 2020, dos amigas xalapeñas, Laura y Mariana, que compartían el amor por los animales y el medio ambiente, comenzaron a notar un problema en común: la gran cantidad de desperdicios textiles y plásticos que se acumulaban en la ciudad. Inspiradas por sus propias mascotas, tuvieron la idea de reutilizar ropa vieja y materiales reciclados para transformarlos en camas, juguetes y ropa para perros y gatos.

Al inicio, trabajaban desde casa. Con máquinas de coser prestadas y retazos donados por vecinos, fabricaban sus primeros productos y los vendían en bazares locales. La respuesta fue positiva: muchos clientes apreciaban que, además de ser artículos para sus mascotas, también contribuyen a reducir el impacto ambiental.

En 2021, gracias al apoyo de una convocatoria del Ayuntamiento de Xalapa para emprendedores verdes, **pudieron abrir su primer local en la colonia centro, con el nombre “Perrito Reciclado”. Su catálogo ya incluía:**

- *Juguetes de tela reciclada.*
- *Collares y correas hechos con botellas PET trituradas y reforzadas.*
- *Ropa para mascotas confeccionada con mezclilla reutilizada.*
- *Camas elaboradas con relleno de algodón reciclado.*

En 2022, durante la pandemia, comenzaron a vender en línea, lo cual les permitió sobrevivir y llegar a clientes de todo Veracruz. En 2023 ampliaron su negocio ofreciendo también un servicio de trueque ecológico, donde los clientes podían llevar ropa vieja o telas a cambio de descuentos.

Hoy en 2025, Perrito Reciclado es reconocida como un referente de innovación sostenible en la región, con clientes leales y convenios con veterinarias locales.

Introducción | ¿Qué decisión se busca optimizar o definir?

Durante nuestro contacto con Perrito Reciclado, se nos fue proporcionado un histórico de datos provenientes del año 2024, dicho histórico fue presentado en distintos formatos como lo fue un documento de Excel y una presentación en Power BI, lo que nos permitió analizar y determinar qué proceso es en el que nos queremos centrar para ayudar a una toma de decisiones óptima.

De esta manera, identificamos que existe una necesidad por parte de Perrito Reciclado, la cual es la retención de clientes junto con la optimización/creación de medidas y estrategias de retención para los mismos.

Así que, con esta información y según los históricos proporcionados, el proceso que se busca optimizar o predecir se centra en un **proceso orientado al cliente, específicamente: la clasificación y retención de clientes,** y por ende, en la optimización de las estrategias de **Customer Relationship Management (CRM)** de Perrito Reciclado.

Esto se logra mediante la implementación de un **Sistema de Apoyo a la Toma de Decisiones (DSS) orientado al conocimiento.**

Nuestro DSS se clasifica como orientado al conocimiento, ya que no solo utiliza el histórico de datos para realizar predicciones, sino que también integra y gestiona **reglas del negocio e heurísticas** predefinidas por la empresa para un uso prescriptivo (por ejemplo, las acciones como "Ofrecer envío gratuito" o "Descuento de bienvenida").

El sistema aplica este conocimiento para interpretar los resultados del modelo predictivo y generar las recomendaciones de acción específicas para cada segmento de cliente, **por lo que además el sistema posee un enfoque mixto o híbrido Predictivo-Prescriptivo.**

Introducción | Objetivos generales y específicos.

El objetivo general de este proyecto, es "**desarrollar un Sistema de Apoyo a la Decisión (DSS) Inteligente de naturaleza híbrida, enfocado y orientado a la clasificación y retención de clientes**".

Este enfoque híbrido permite transformar los **datos históricos** (el pasado) en **predicciones** (el futuro) y, finalmente, en **decisiones operativas** (el presente), cerrando el ciclo del sistema híbrido.

Para maximizar el impacto que se puede generar con un DSS orientado al conocimiento, este informe propone desarrollar un **sistema híbrido Predictivo-Prescriptivo** con los siguientes componentes:

Componente	Objetivo	Metodología	Ejemplo de Acción
Predictivo	Predecir/Anticipar la clasificación y el nivel de retención de clientes para poder generar una correcta y eficaz toma de decisiones .	Entrenamiento de un algoritmo de Árbol de Decisión para clasificar clientes en categorías de lealtad ("Cliente Frecuente" vs. "Cliente poco frecuente"), utilizando la librería Scikit-learn en Python.	Predicción: Probabilidad de fidelidad del 85%, el cliente de Xalapa posee una alta probabilidad de ser un cliente frecuente.
Prescriptivo	Sugerir las acciones de negocio automatizadas y basadas en evidencia.	Integración de reglas de negocio derivadas del análisis heurístico actual de la empresa (proporcionadas en los históricos de la empresa).	Prescripción: El sistema sugiere "Ofrecer envío gratuito" o "Descuento de bienvenida".
Interfaz de Usuario	Diseñar una interfaz de usuario que permita seleccionar entre distintos usuarios y observar las recomendaciones que el sistema proporciona.	Se eligió Streamlit como interfaz de usuario debido a su integración nativa con el ecosistema de Python (Scikit-learn/Pandas), lo que permite una visualización de datos en tiempo real. Esto facilita que los tomadores de decisiones interactúen con el modelo predictivo sin necesidad de conocimientos técnicos complejos.	Interfaz: Visualización de una interfaz en la que los usuarios puedan seleccionar al cliente que se quiera analizar o predecir y recibir un porcentaje de probabilidad y una recomendación prescriptiva.

Marco Teórico

El **Marco Teórico** de este proyecto estará estructurado para establecer una base conceptual sólida y justificar las herramientas tecnológicas seleccionadas. Se dividirá en dos secciones principales.

- **Definición y explicación de los conceptos centrales** : Esta sección detalla los pilares teóricos sobre los que se fundamenta el Sistema de Apoyo a la Toma de Decisiones (SATD) propuesto.
- **Descripción y justificación de la herramienta utilizada:** Esta sección se centra en justificar de manera lógica la elección de la herramienta que se usó para desarrollar tanto el modelado de nuestro algoritmo de árbol de decisión hasta el desarrollo de la Interfaz de usuario final para el DSS (Sistema de Apoyo a la Toma de Decisiones).

El desarrollo de cada uno de estos puntos se presentará más a continuación en la redacción de este informe.

Marco Teórico | Definición y explicación de los conceptos centrales

Sistemas de Apoyo a la Toma de Decisiones (SATD/DSS)

Un sistema de apoyo a la Toma de Decisiones o DSS por sus siglas en Inglés **es un sistema de información diseñado para ayudar a los miembros de una organización a tomar decisiones** en situaciones de carácter poco claras o inciertas.

Históricamente, los DSS se centraban en informes descriptivos (análisis retrospectivo). Sin embargo, **la tendencia moderna ha desplazado el foco hacia la Analítica Predictiva y Prescriptiva.**

El objetivo de un DSS no es automatizar la decisión (es decir, el sistema no decide por ti), sino proporcionar las **herramientas necesarias para que el humano tome la mejor decisión** posible basándose en hechos y proyecciones.

Arquitectura de un DSS

Un DSS típico se compone de tres partes fundamentales que trabajan juntas:

- **Base de Datos (Gestión de Datos):** Recopila información interna (ventas, producción) y externa (datos de mercado, economía). Puede conectarse a distintos tipos de bases de datos.
- **Base de Modelos (Gestión de Modelos):** Es el "cerebro" matemático. Contiene modelos estadísticos, financieros, de simulación o de optimización que permiten analizar los datos.
- **Interfaz de Usuario:** Es la parte visual (dashboards, gráficos) que permite al usuario interactuar con el sistema sin necesidad de ser un programador experto.

Tipos de DSS

Existen diversas maneras de clasificar los DSS, pero la más común normalmente se distinguen entre 5 tipos según su enfoque principal

- **Orientados a Datos:** Se enfocan en el acceso y manipulación de grandes bases de datos (Data Warehousing / Business Intelligence).
- **Orientados a Modelos:** Se enfocan en el uso de modelos financieros o de simulación. Ejemplo: Una hoja de cálculo compleja para proyecciones fiscales.
- **Orientados al Conocimiento:** Sugieren acciones basándose en reglas predefinidas (Sistemas Expertos), **aquí es donde recae nuestro sistema DSS.**
- **Orientados a Documentos:** Gestionan y recuperan información no estructurada (documentos, políticas, páginas web) para ayudar en la decisión.
- **Orientados a la Comunicación:** Facilitan la colaboración de un grupo para tomar una decisión compartida (Groupware).

Tipos de Modelos en Análisis de datos

Estos tres tipos de modelos representan la escalera de valor en el análisis de datos. Básicamente, responden a tres preguntas diferentes sobre tu negocio o proyecto: **¿Qué pasó?, ¿Qué pasará? y ¿Qué deberíamos hacer?.**

Modelos Descriptivos (El espejo retrovisor)

Son los más comunes. Analizan datos históricos para entender qué ha sucedido hasta ahora. No predicen nada, solo organizan la realidad para que sea comprensible.

Los Modelos Descriptivos constituyen la base de la analítica de datos y son, por mucho, los más utilizados en cualquier organización.

Su objetivo fundamental es analizar datos históricos (eventos, transacciones, comportamientos, métricas de rendimiento) para responder a la pregunta: **"¿Qué ha sucedido?"** y **"¿Por qué ha sucedido?"**.

Actúan como un "espejo retrovisor" porque **se centran exclusivamente en el pasado y el presente inmediato, sin intentar predecir el futuro.** Su valor reside en convertir grandes volúmenes de datos brutos en información coherente, organizada y comprensible para la toma de decisiones.

Aunque son los más sencillos, son indispensables. Al ofrecer una visión clara y estructurada de lo que ha ocurrido, **los Modelos Descriptivos proporcionan el contexto necesario.**

Responden a la necesidad básica de tener un diagnóstico preciso antes de intentar prescribir una acción o predecir un resultado. Sin este conocimiento fundamental, cualquier modelo más avanzado (como los predictivos o prescriptivos) carecería de una base sólida y una referencia histórica para validar sus resultados.

Modelos Predictivos (La bola de cristal)

Utilizan matemáticas, estadística y algoritmos (Machine Learning) sobre los datos históricos para identificar patrones y proyectar comportamientos futuros. No te dicen qué decisión tomar, solo te alertan de lo que es probable que ocurra.

Los Modelos Predictivos toman como base la información organizada por los modelos descriptivos y la utilizan para proyectar resultados futuros. Son una herramienta fundamental en la gestión de riesgos, la planificación estratégica y la **personalización de la experiencia del cliente.**

Su objetivo fundamental es usar datos (históricos y en tiempo real) para responder a la pregunta: "¿Qué sucederá?" y "¿Qué tan probable es que suceda?".

Actúan como una "bola de cristal" porque **su foco está en el futuro. Se basan en el principio de que los patrones del pasado se repetirán en el futuro, permitiendo estimar una probabilidad o un valor futuro** (como la probabilidad de que un cliente se dé de baja o el precio futuro de un activo). Su valor reside en la anticipación y la capacidad de informar sobre la incertidumbre futura.

Son modelos complejos que requieren una base de datos limpia y la aplicación de técnicas avanzadas de Machine Learning (como regresiones, clasificación y series de tiempo).

Aunque su resultado es invaluable para la toma de decisiones, es crucial entender que su salida siempre será una probabilidad o una estimación, no una certeza.

Proporcionan la anticipación necesaria. Responden a la necesidad básica de estar preparados para el futuro, alertando sobre riesgos u oportunidades, y sirven como puente indispensable para el siguiente nivel de analítica: la prescripción.

Modelos Prescriptivos (El GPS inteligente)

Es el nivel más avanzado. No solo predice el futuro, sino que recomienda acciones específicas para aprovechar una oportunidad o evitar un riesgo. Utiliza simulación y optimización para encontrar la mejor ruta.

Los Modelos Prescriptivos se construyen sobre la base de los modelos descriptivos y predictivos. Representan la culminación del análisis de datos, ya que su propósito es ir más allá de la comprensión y la predicción para influir activamente en el resultado futuro.

Son cruciales en la gestión de la cadena de suministro, la optimización de precios y la toma de decisiones operativas complejas.

Su objetivo fundamental es utilizar datos, predicciones y restricciones operativas para responder a la pregunta: "¿Qué deberíamos hacer?" y "¿Cómo podemos lograr el mejor resultado?"

Actúan como un "GPS inteligente" porque su foco está en la acción óptima. Se basan en técnicas de optimización (programación lineal, no lineal, dinámica) y simulación, buscando la mejor decisión o conjunto de decisiones que maximice un objetivo (ganancia, eficiencia) o minimice una restricción (costo, riesgo). Su valor reside en la automatización de la decisión y la garantía de que se toma la mejor opción posible.

Son, por definición, los modelos más complejos. Requieren una base de datos limpia, la aplicación de técnicas avanzadas de Machine Learning y, fundamentalmente, la **incorporación de reglas de negocio y restricciones operativas** que definen qué acciones son viables.

Proporcionan la dirección necesaria. **Responden a la necesidad básica de tener un plan de acción optimizado**, convirtiendo el conocimiento del pasado y la anticipación del futuro en decisiones concretas y ejecutables.

Gestión de Relaciones con el Cliente (CRM) y Principio de Pareto

Para fundamentar la necesidad del sistema desde una perspectiva administrativa, **el proyecto se apoya en el concepto de Customer Relationship Management (CRM) analítico**. El objetivo no es solo vender, sino maximizar el valor de vida del cliente (CLV).

Esta estrategia se basa en el **Principio de Pareto (Regla 80/20)** aplicada a ventas, la cual postula que, en muchas empresas, **el 80% de los ingresos provienen del 20% de los clientes más leales**.

El sistema "El Sabueso" busca identificar tecnológicamente a ese 20% vital (Clientes Frecuentes) **para aplicar estrategias de retención diferenciadas**, optimizando así los recursos de marketing de la PyME.

Aclaración: **PyME** es el acrónimo de **Pequeña y Mediana Empresa**.

Árboles de Decisión

Un Árbol de Decisión es una de las técnicas (algoritmos) más populares dentro del Machine Learning Supervisado. Funciona como un diagrama de flujo jerárquico que imita el razonamiento humano.

- **Estructura:** El punto de partida (la pregunta más importante).
- **Nodos:** Puntos de decisión donde se evalúa una variable (¿Tiene Facebook?).
- **Ramas:** Los caminos posibles (Si/No).
- **Hojas:** La decisión o predicción final (Cliente Frecuente / No Frecuente).

Para poder analizar y responder preguntas como: ¿Cómo decide el árbol qué pregunta poner primero? ¿Por qué eligió "Veces Comprado" antes que "Sexo"?, **se necesitan entender los siguientes conceptos clave:**

- **Entropía (Entropy):** Es una medida que viene de la termodinámica y la teoría de la información. Mide el **grado de desorden, impureza o incertidumbre** en un conjunto de datos.

Si tienes una canasta con 100 manzanas rojas, **la entropía es 0** (Orden total, sabemos qué va a salir), si tienes 50 manzanas y 50 peras, la entropía es **1** (Desorden máximo, máxima incertidumbre).

El algoritmo busca reducir la entropía. Quiere pasar de grupos mezclados a grupos puros.

- **Índice Gini (Gini impurity):** Es una métrica alternativa a la Entropía para medir la impureza. Es la que se usó en el modelo final de ML de nuestro proyecto.

Mide la probabilidad de que, si tomas un elemento al azar y lo etiquetas al azar según la distribución del grupo, te equivoques. Va de 0 (pureza total) a 0.5 (máxima impureza en clasificación binaria).

Matemáticamente son muy similares, pero Gini es computacionalmente más rápido de calcular (porque no usa logaritmos complejos, solo sumas y cuadrados).

- **Ganancia de Información (Information Gain):** Es el criterio de éxito. **Es la diferencia entre la entropía que había antes de hacer una pregunta y la entropía que queda después.**

¿Cómo selecciona el árbol la mejor pregunta para filtrar todo?, primero prueba dividir por "Edad": La ganancia es baja (los grupos siguen mezclados), luego el árbol prueba dividir por "Gasto": La ganancia es media, finalmente el árbol prueba dividir por "Veces Comprado": **La ganancia es alta (los grupos resultantes son muy puros). El algoritmo elige la pregunta con la Mayor Ganancia de Información para colocarla en el nodo.**

Sobreajuste (Overfitting) en Modelos Predictivos

Un desafío crítico en la construcción de Árboles de Decisión es el fenómeno del Sobreajuste. Esto ocurre cuando el modelo se vuelve excesivamente complejo y, en lugar de aprender los patrones generales de los datos, "memoriza" el ruido o las fluctuaciones aleatorias del set de entrenamiento.

Un modelo sobreajustado tendrá una precisión perfecta (100%) con los datos históricos, pero fallará estrepitosamente al intentar predecir nuevos clientes reales.

La técnica de Poda (Pruning) o la limitación de la profundidad del árbol (parametro max_depth), aplicada en este proyecto, sirve para simplificar el modelo y garantizar su capacidad de generalización.

One-Hot Encoding

Es una técnica de preprocesamiento de datos utilizada en Machine Learning para convertir variables categóricas (texto o etiquetas) en una representación numérica binaria que los algoritmos puedan procesar matemáticamente.

A diferencia de la codificación ordinal (donde se asignan números enteros como 1, 2, 3), el **One-Hot Encoding evita introducir una jerarquía o relación de orden artificial entre las categorías.** La técnica consiste en crear una nueva columna (variable dummy) para cada categoría única presente en la variable original.

Si la categoría está presente en el registro, se asigna el valor 1 (Hot). Si no está presente, se asigna el valor 0 (Cold).

En el sistema "El Sabueso", esta técnica se implementó a través de la función `pd.get_dummies` de la librería **Pandas**. Fue fundamental para transformar variables cualitativas nominales como "Tipo de Mascota", "Profesión" y "Estado Civil", permitiendo que el Árbol de Decisión pudiera evaluar estas características sin sesgos numéricos derivados de un ordenamiento arbitrario.

Matriz de Confusión

Es una herramienta de visualización y evaluación del desempeño de un algoritmo de aprendizaje supervisado. Se estructura como una tabla cuadrangular que compara las predicciones realizadas por el modelo (columnas) contra los valores reales observados en el dataset (filas).

Su importancia radica en que permite distinguir entre dos tipos de errores:

- **Error Tipo I (Falso Positivo):** Identificar erróneamente un caso negativo como positivo.
- **Error Tipo II (Falso Negativo):** Fallar en la identificación de un caso positivo real.

Esta distinción es crítica para ajustar el modelo según la sensibilidad requerida por la estrategia de negocio de la organización.

Para este negocio, un **Falso Negativo** es peor. Porque si le damos un descuento por error a un extraño (Falso Positivo), solo perdemos unos pesos. Pero si ignoramos a un cliente leal (Falso Negativo), perdemos todo su valor de vida (LTV) futuro

Métricas de Evaluación para Clasificadores

Para determinar la efectividad teórica del modelo, no basta con medir la exactitud global (*Accuracy*). **Se utilizan herramientas más granulares como la Matriz de Confusión**, la cual desglosa los aciertos y errores en cuatro cuadrantes:

1. **Verdaderos Positivos (VP):** Clientes frecuentes identificados correctamente.
2. **Verdaderos Negativos (VN):** Clientes no frecuentes identificados correctamente.
3. **Falsos Positivos (Error Tipo I):** Predecir que alguien será cliente frecuente cuando no lo será (Riesgo: Gasto innecesario en descuentos).
4. **Falsos Negativos (Error Tipo II):** No identificar a un cliente VIP potencial (Riesgo: Pérdida de oportunidad de venta).

Inteligencia Artificial (IA) y Machine Learning en el contexto de SATD

La inteligencia artificial es la rama general de la informática que busca simular procesos de inteligencia humana mediante máquinas, especialmente sistemas computacionales. **Estos procesos incluyen el aprendizaje, el razonamiento y la autocorrección.**

El Machine Learning es un subcampo de la IA. Se refiere a la capacidad de los sistemas para aprender automáticamente y mejorar a partir de la experiencia (datos) sin ser programados explícitamente para cada regla.

La principal relación entre estos conceptos y el DSS es su implementación y evolución, un DSS tradicional utiliza herramientas estadísticas básicas o consultas a bases de datos (SQL) para mostrar qué pasó. Responde a: "*¿Cuántos clientes tuvimos ayer?*". **Un DSS inteligente incorpora componentes de IA y Machine Learning.** No solo muestra datos, sino que **predice y sugiere.** Responde a: "*¿Este cliente volverá mañana?*".

El Machine Learning actúa como el "Motor de Inferencia" dentro del DSS, mientras que el DSS es el cuerpo (La interfaz, la base de datos, los botones). **La IA es un modelo de Machine Learning que funciona como el cerebro para la toma de decisiones** dentro de la interfaz.

Metodología CRISP-DM

La metodología **CRISP-DM (Cross-Industry Standard Process for Data Mining)** es un **modelo de proceso estándar de la industria para guiar los proyectos de minería de datos.** Se compone de seis fases interconectadas:

1. **Comprensión del Negocio:** Determinar los objetivos del negocio y traducirlos en un problema de minería de datos.
2. **Comprensión de los Datos:** Recopilar, describir y explorar los datos para identificar problemas de calidad.
3. **Preparación de los Datos:** Limpieza, selección, construcción y formato de los datos para la modelización.
4. **Modelado:** Seleccionar y aplicar técnicas de modelado (algoritmos) y calibrar sus parámetros.
5. **Evaluación:** Evaluar los resultados del modelo respecto a los objetivos del negocio y decidir si el modelo es aceptable.
6. **Despliegue:** Poner el modelo en uso para generar las predicciones o conocimientos deseados.

Investigación aplicada

La **Investigación Aplicada** es un tipo de investigación científica que se centra en **encontrar soluciones prácticas a problemas específicos y concretos**.

Su objetivo principal es **utilizar la teoría, el conocimiento y los métodos científicos existentes para desarrollar tecnología, técnicas o herramientas que puedan aplicarse directamente para mejorar una condición o resolver un problema en la vida real**.

A diferencia de la investigación pura o básica (que busca ampliar el conocimiento sin una aplicación práctica inmediata), la investigación aplicada está orientada a la acción y a la solución.

Programación Literaria

Es un paradigma de programación propuesto por **Donald Knuth** (un gigante de la computación) en 1984.

Su filosofía es simple pero revolucionaria:

"En lugar de escribir código para que lo entienda la computadora, deberíamos escribirlo para que lo entienda un ser humano."

En la programación tradicional, tú escribes puras instrucciones lógicas. Los comentarios son secundarios. En la **Programación Literaria**, tú escribes un **documento narrativo** (como un ensayo o un libro de texto) donde el código está incrustado entre párrafos de explicación.

El uso de Google Colab permitió adoptar el paradigma de **Programación Literaria (Literate Programming)**. Este enfoque metodológico integra el código ejecutable (Python), la visualización de resultados (Gráficas) y la narrativa explicativa en un solo documento vivo. Esto facilita la auditoría del algoritmo, ya que permite a los revisores entender no solo 'qué' hace el código, sino 'por qué' se tomaron ciertas decisiones de diseño durante el entrenamiento del modelo.

Marco Teórico | Descripción y Justificación de la Herramienta Utilizada

El sistema DSS desarrollado para este proyecto, denominado "El Sabueso", no depende de una única herramienta, sino que se construye sobre un ecosistema tecnológico modular (es decir, se usaron múltiples herramientas) **basado en Python.**

Esta arquitectura permite al equipo desarrollar con flexibilidad, escalabilidad y una clara separación entre el entrenamiento del modelo y la interfaz de usuario

A continuación, **presentamos y justificamos cada una de las herramientas fundamentales para la creación del DSS, categorizando en función del ciclo de vida del desarrollo del proyecto:**

1. Lenguaje Base y Entorno de Desarrollo

Python (v3.11)

Python es un lenguaje de programación de alto nivel, interpretado, de propósito general y multiparadigma (soporta programación orientada a objetos, imperativa y funcional). Se caracteriza por una sintaxis limpia y legible que prioriza la claridad del código, reduciendo el costo de mantenimiento del software.

Seleccionado como el lenguaje de programación para el proyecto por ser el estándar global en Ciencia de Datos e Inteligencia Artificial, es el lenguaje dominante indiscutible en el campo del Machine Learning, librerías como Scikit-learn (tu cerebro predictivo) y Pandas (tu gestor de datos) son nativas de Python.

Su sintaxis clara y su amplia colección de bibliotecas especializadas **permitieron unificar el desarrollo**, utilizar el mismo lenguaje para todo logró un desarrollo ágil tanto del backend matemático como del frontend visual.

Google Colab (Entorno de Entrenamiento)

Google Colaboratory, conocido comúnmente como "Colab", **es un entorno de ejecución de Jupyter Notebooks alojado en la nube por Google.**

Permite escribir, ejecutar y compartir código en lenguaje Python directamente desde el navegador web, sin necesidad de configuración previa en el equipo local.

Se utilizó esta plataforma en la nube **para** la fase de **ingeniería de datos y entrenamiento del modelo.**

Su **formato de 'cuaderno'** permitió combinar celdas de código ejecutable con bloques de texto explicativo (Markdown), **facilitando la documentación técnica del proceso y de entrenamiento.**

Permitió al equipo trabajar de forma colaborativa en tiempo real, garantizando un entorno unificado con las mismas versiones de librerías y ofreciendo recursos de cómputo (RAM/CPU) superiores para procesar el dataset (conjunto de datos) sin depender del hardware local.

Visual Studio Code (Entorno de Despliegue)

Visual Studio Code (comúnmente conocido como VS Code) **es un editor de código fuente** ligero pero potente desarrollado por Microsoft, es una aplicación de escritorio que combina la simplicidad de un editor de texto con herramientas avanzadas para desarrolladores, como depuración (debugging), ejecución de tareas y control de versiones.

Su ecosistema permite instalar complementos para todo (Python, Streamlit, Excel), convirtiéndolo en una herramienta personalizada.

Se eligió para la fase de despliegue, **utilizado para la programación de la interfaz final (app.py), la integración de los archivos del modelo y la ejecución del servidor web de Streamlit directamente desde la terminal del sistema operativo.**

2. Ingeniería y Preprocesamiento de Datos (ETL)

Pandas

Pandas es una biblioteca de software escrita para el lenguaje de programación Python, diseñada específicamente para la manipulación y el análisis de datos, es una de las bibliotecas fundamentales para la manipulación de estructuras de datos.

La estructura principal de Pandas es el **DataFrame**, que puede entenderse como una tabla programable en memoria (similar a una hoja de cálculo de Excel o una tabla SQL), pero con capacidades de procesamiento mucho mayores.

DataFrame y Pandas fueron indispensables para el procesamiento de los datos históricos desde el archivo Excel (.xlsx), permitió la conexión directa con los archivos fuente de la organización, hizo la limpieza de valores nulos (dropna), y la transformación de variables categóricas mediante técnicas de One-Hot Encoding (get_dummies), convirtiendo datos cualitativos (como "Tipo de Mascota" o "Profesión") en formatos numéricos interpretables por el algoritmo (en matrices de formato binario).

3. Modelado Predictivo e Inteligencia Artificial

Scikit-learn (sklearn)

Scikit-learn (abreviado comúnmente como sklearn) es una biblioteca de código abierto para aprendizaje automático (Machine Learning) construida sobre el ecosistema científico de Python (NumPy, SciPy y Matplotlib).

Provee herramientas eficientes y simples para el análisis predictivo de datos, incluyendo algoritmos de clasificación, regresión, agrupamiento (clustering) y reducción de dimensionalidad.

Contiene un montón de implementaciones robustas de algoritmos clásicos como Árboles de Decisión (CART, que es el que usamos para nuestro DSS), Máquinas de Soporte Vectorial (SVM) y Bosques Aleatorios (Random Forest), también incluye funciones integradas para medir la precisión de los modelos (Matriz de Confusión, Accuracy Score), vitales para validar que la IA funciona correctamente.

Funciona como el motor cerebral de nuestro DSS, provee la implementación optimizada del algoritmo CART (Classification and Regression Trees) utilizado para el Árbol de Decisión requerido para el proyecto.

Además, la librería no solo entrena, sino que ayuda a preparar los datos, **facilitó la codificación de variables objetivo**, utilizamos su herramienta “LabelEncoder” para traducir las etiquetas de texto ("Sí/No") a valores binarios comprensibles para la máquina.

A través de su integración nativa con Joblib, se pudo conservar y exportar el modelo desde el entorno de entrenamiento en la nube hacia la aplicación final de escritorio (guardándolo en formato .pkl), logrando que la inteligencia entrenada pudiera ser transportada y ejecutada en la interfaz de usuario sin necesidad de re-entrenar en cada uso.

4. Visualización e Interpretabilidad

Matplotlib

Matplotlib es una biblioteca completa para la creación de generación de gráficos estáticos, animados e interactivos en Python. Es una de las herramientas fundacionales del ecosistema científico (SciPy Stack). Su módulo principal, pyplot, ofrece una interfaz similar a la de MATLAB, permitiendo generar gráficos de alta calidad listos para publicación académica.

Permite crear desde histogramas y diagramas de dispersión básicos hasta gráficos 3D complejos y mapas de calor. **Funciona nativamente con las estructuras de datos de Pandas y Scikit-learn.**

Una de las ventajas competitivas del algoritmo CART es que no es una "Caja Negra", sino una "Caja Blanca" o "Interpretable", esto significa que su estructura de nodos y ramas es inherentemente transparente y permite trazar el camino exacto que llevó a una predicción.

Sin embargo, las reglas matemáticas internas son difíciles de leer para un humano, por lo que **utilizamos Matplotlib para renderizar gráficamente la estructura del árbol, permitiendo al equipo y a los directivos ver literalmente cómo piensa la IA.**

Gracias a los gráficos generados, pudimos detectar visualmente la diferencia entre el "Modelo Chico" (muy simple) y el "Modelo Grande" (más detallado), facilitando la justificación de la elección final (esto se explicará más detalladamente en la sección de la metodología del proyecto).

5. Interfaz de Usuario y Despliegue (Frontend)

Streamlit

Streamlit es un framework de código abierto en Python diseñado específicamente para la creación rápida de aplicaciones web orientadas a datos.

A diferencia de los frameworks web tradicionales (como Django o Flask), Streamlit abstrae la complejidad del desarrollo frontend (HTML, CSS, JavaScript), permitiendo a los científicos de datos transformar scripts de Python en interfaces interactivas y visualmente atractivas con pocas líneas de código.

Toda la interfaz (botones, sliders, gráficos) se define usando sintaxis estándar de Python, sin necesidad de aprender lenguajes de diseño web.

Streamlit permitió construir una Interfaz Web Interactiva de manera rápida y eficiente, alineó el desarrollo con los tiempos académicos del proyecto, permitiendo enfocar el esfuerzo en la calidad del modelo predictivo (backend) en lugar de en la estética web.

Al estar basado en Python, Streamlit carga nativamente los archivos .pkl generados por Scikit-learn. No fue necesario crear APIs complejas ni microservicios para conectar la inteligencia artificial con la pantalla del usuario; todo ocurre en el mismo entorno de memoria.

Estado del arte

Estado del Arte (State of the Art) no es solo una lista de libros. Es una **investigación sobre la investigación**. Su objetivo es responder: "¿Qué se ha dicho y hecho recientemente sobre mi tema?"

Sirve para:

1. **No reinventar la rueda:** Demostrar que sabes lo que otros ya intentaron.
2. **Justificar tu aporte:** Decir "Ellos hicieron esto, pero mi proyecto es diferente/mejor por X razón".
3. **Validar tu método:** Mostrar que usar Árboles de Decisión para clientes es una técnica científicamente aceptada.

A continuación, se presenta el análisis de tres trabajos académicos previos que implementaron soluciones de Inteligencia de Negocios y Minería de Datos.

Estos estudios fueron seleccionados por su relevancia directa con el contexto de PyMEs, el sector comercial y la aplicación del algoritmo de Árboles de Decisión.

Aclaración: **PyME** es el acrónimo de **Pequeña y Mediana Empresa**.

Estado del Arte | Minería de Datos para PyMEs

Referencia APA: Valderrama, B., & Rujano, M. (2018). *Minería de datos como herramienta de apoyo en la toma de decisiones en las Pymes comerciales*. Revista Científica Electrónica de Ciencias Humanas, 14(40), 55-70. (Disponible en repositorios como Dialnet o Latindex).

Los autores investigan la barrera tecnológica que impide a las Pequeñas y Medianas Empresas (PyMEs) utilizar sus datos históricos. Proponen una metodología simplificada para aplicar minería de datos en negocios minoristas con recursos limitados, enfocándose en descubrir patrones de ventas sin necesidad de software costoso.

Al igual que en "Perrito Reciclado", este estudio aborda el problema de una empresa que genera datos (ventas, clientes) pero no los explota, el estudio de Valderrama es más teórico y metodológico, mientras que nuestro proyecto ("El Sabueso") es una implementación práctica con un producto de software funcional (la App).

Para nosotros, validó nuestra hipótesis de que no se requiere Big Data (millones de datos) para obtener valor. Nos confirmó que, para una PyME, la limpieza de datos (Data Cleaning) es la fase más crítica, lo que justificó el tiempo que invertimos arreglando el Excel de clientes.

Estado del Arte | Predicción de Fuga de Clientes

Referencia APA: Montoya, D., & Parra, A. (2020). *Modelo predictivo para la deserción de clientes utilizando técnicas de minería de datos*. Información Tecnológica, 31(1), 143-152. (Revista indexada en Scielo).

Este trabajo técnico compara varios algoritmos (incluyendo Árboles de Decisión J48 y Redes Neuronales) para predecir si un cliente dejará de comprar en una empresa de servicios. Utilizaron variables como "frecuencia de uso" y "monto de facturación" para entrenar al modelo.

Utilizan las mismas métricas clave que nosotros: Frecuencia (Veces Comprado) y Valor Monetario (Cantidad Gastada), su enfoque es negativo ("¿Quién se va a ir?"), mientras que nuestro DSS tiene un enfoque positivo/prescriptivo ("¿Quién es leal y cómo lo recompenso?").

El estudio concluyó que los Árboles de Decisión ofrecían la mejor interpretabilidad para los gerentes frente a las Redes Neuronales. Esto cimentó nuestra decisión técnica de usar el algoritmo CART en Scikit-learn, priorizando que el dueño de "Perrito Reciclado" pudiera entender las reglas del negocio (Gráfico del Árbol) en lugar de usar una "caja negra".

Estado del Arte | Segmentación y perfilado de Clientes

Referencia APA: Silva, J., & Romero, J. (2021). *Segmentación de clientes en el comercio electrónico mediante algoritmos de aprendizaje automático*. RISTI - Revista Ibérica de Sistemas e Tecnologías de Informação, (E42), 299-311.

Analiza cómo agrupar a los clientes de un e-commerce según sus hábitos de compra para ofrecer campañas de marketing personalizadas. El estudio demuestra que segmentar a los clientes por comportamiento (qué hacen) es más efectivo que solo por demografía (quiénes son).

El uso de una interfaz para visualizar los segmentos. Coincide con nuestra propuesta de usar colores (Semáforo) para clasificar a los usuarios, Ellos aplicaron aprendizaje *No Supervisado* (Clustering), mientras que nosotros usamos *Supervisado* (ya sabíamos quién era Cliente Frecuente).

Metodología

Para el desarrollo del Sistema de Apoyo a la Toma de Decisiones (DSS) "El Sabueso", se adoptó un enfoque de Investigación Aplicada, instrumentado a través de la metodología estándar de la industria para minería de datos: **CRISP-DM (Cross-Industry Standard Process for Data Mining)**.

Esta metodología se seleccionó por su estructura cíclica y flexible, la cual permite iterar entre la comprensión de los datos y el ajuste del modelo predictivo, garantizando que la solución tecnológica (el software) esté perfectamente alineada con los objetivos estratégicos de la organización "Perrito Reciclado".

A continuación, se detallan las seis fases del ciclo de vida del proyecto implementadas.

Metodología | Fase 1: Comprensión del Negocio.

El objetivo inicial fue traducir la necesidad operativa de la empresa en un problema de Data Science.

- **Problemática:** La organización carecía de herramientas para identificar *a priori* qué clientes nuevos tenían el potencial de convertirse en compradores recurrentes de alto valor.
- **Objetivo del DSS:** Desarrollar un modelo predictivo capaz de clasificar a un cliente como "Frecuente" o "No Frecuente" en el momento de su primera o segunda interacción.
- **Estrategia Prescriptiva:** Se definió que el sistema no solo debía predecir (output binario), sino sugerir acciones de retención (descuentos, membresías VIP) basadas en la probabilidad de fidelidad.

Metodología | Fase 2: Comprensión de los Datos

Se procedió a la recolección y análisis exploratorio del dataset histórico proporcionado por la empresa.

Fuente de Datos: Archivo maestro.

Volumen: El dataset final consta de 143 registros (instancias) de clientes históricos.

Tipología de Variables: Se identificó una estructura de datos mixta:

- **Variables Numéricas (Cuantitativas):** EDAD, CANTIDAD GASTADA (Ticket promedio), VECES COMPRADO EN LA TIENDA (Frecuencia).
- **Variables Categóricas (Cualitativas):** TIPO DE MASCOTA (7 categorías), PROFESIÓN, ESTADO CIVIL, MEDIO DE CONTACTO.

Calidad Inicial: Se detectaron inconsistencias menores en la estandarización de textos (ej: duplicidad de géneros en profesiones), las cuales fueron documentadas para su corrección en la siguiente fase.

Metodología | Fase 3: Preparación de los Datos

Esta fase constituyó la etapa de ingeniería más crítica del proyecto, ejecutada mediante la librería **Pandas** en Python. Se aplicaron procesos de **ETL (Extract, Transform, Load)**:

1. Limpieza de Datos (Data Cleaning):

- Se eliminaron espacios en blanco redundantes en los nombres de las columnas (strip).
- Se verificó la integridad del dataset mediante la eliminación de registros con valores nulos (dropna), asegurando que el modelo no aprendiera de datos incompletos.

2. Ingeniería de Características (Feature Engineering):

- **Transformación de Tipos:** Se forzó la conversión de variables numéricas (to_numeric) para evitar errores de interpretación de texto.
- **Codificación de la Variable Objetivo:** Se utilizó LabelEncoder para transformar la variable dependiente "CLIENTE FRECUENTE" (Sí/No) a valores binarios (1/0).
- **Codificación One-Hot (Get Dummies):** Dado que el algoritmo de Árbol de Decisión requiere entradas numéricas, se aplicó la técnica de *One-Hot Encoding* a las variables categóricas. Esto expandió características como "Mascota" en múltiples columnas binarias (ej: Mascota_Perro, Mascota_Gato), permitiendo al modelo ponderar matemáticamente la influencia de cada categoría sin asignar un orden jerárquico erróneo.

Metodología | Fase 4: Modelado (Modeling)

Se seleccionó el algoritmo CART (Classification and Regression Trees) implementado en la librería **Scikit-learn**.

Configuración del Modelo (Hiperparámetros):

- **Profundidad Máxima (max_depth=5):** Se limitó el crecimiento del árbol a 5 niveles. Esta decisión técnica se tomó para evitar el **Sobreajuste (Overfitting)**. Un árbol más profundo habría "memorizado" a los 143 clientes exactos; al limitarlo a 5, forzamos al modelo a aprender patrones generalizables (reglas de negocio) aplicables a futuros clientes.
- **Criterio de Impureza (Gini):** Se utilizó el índice Gini para evaluar la calidad de las divisiones en los nodos, priorizando las variables que mejor separaban a los clientes fieles de los esporádicos.

Entrenamiento: El modelo fue alimentado con la matriz de características procesada ("x", o las variables como mascota, veces comprada, etc) y el vector objetivo ("y", es decir, cliente frecuente) mediante el método .fit().

Metodología | Fase 5: Evaluación

Antes del despliegue, se realizó un experimento comparativo A/B de modelos:

- **Modelo A (Robusto - Seleccionado):** Entrenado con la totalidad de las variables, incluyendo cualitativas (Mascota, Profesión).
- **Modelo B (Simplificado):** Entrenado solo con variables numéricas (Gasto, Edad, Frecuencia).
- **Resultado:** Se seleccionó el **Modelo A**. Aunque el Modelo B era computacionalmente más ligero, **el análisis cualitativo demostró que variables como "Tipo de Mascota" eran determinantes para el negocio** (ej: dueños de perros grandes tienden a gastar más frecuentemente). El modelo robusto ofreció una representación más fiel de la realidad del cliente, con un índice Gini o pureza de 0 como resultado final.

Metodología | Fase 6: Despliegue

La fase final consistió en la integración del modelo matemático en una aplicación funcional para el usuario final.

- **Serialización:** Mediante la librería **Joblib**, se exportaron los objetos entrenados (modelo_perrito.pkl, columnas.pkl, traductor.pkl) para asegurar la persistencia del "conocimiento" adquirido.
- **Interfaz de Usuario (Frontend):** Se desarrolló una aplicación web interactiva utilizando el framework **Streamlit** (app.py). Esta interfaz conecta los inputs del usuario con el modelo cargado, visualizando la predicción mediante un "Semáforo de Fidelidad" y generando recomendaciones prescriptivas automatizadas según el rango de probabilidad calculado.

Desarrollo

El desarrollo del Sistema "El Sabueso" siguió un flujo de trabajo lineal y depurado, priorizando la calidad de los datos sobre la cantidad, bajo la premisa de que un modelo de Inteligencia Artificial es tan bueno como la información con la que se alimenta.

Desarrollo | Análisis del Proceso y Selección de Características

El proceso seleccionado para la optimización fue la Retención y Fidelización de Clientes. Originalmente, la información operativa de "Perrito Reciclado" se encontraba dispersa en múltiples hojas de cálculo (**EXCEL4.xlsx**) que mezclaban inventarios, proveedores y tráfico web.

Para el modelo predictivo, se aisló exclusivamente la dimensión del Perfil del Cliente, seleccionando las siguientes variables de entrada (Features) por su relevancia estadística y de negocio:

- **Variables Demográficas:** *Edad, Sexo, Estado Civil y Profesión.* (Permiten identificar perfiles socioeconómicos).
- **Variables Transaccionales:** *Cantidad Gastada y Veces Comprado.* (Indicadores directos de rentabilidad).
- **Variables Psicográficas:** *Tipo de Mascota.* (Variable crítica, ya que el gasto y la frecuencia varían drásticamente entre un dueño de un "Gran Danés" y uno de un "Hámster").
- **Variable Objetivo (Target):** *Cliente Frecuente.* (La etiqueta binaria Sí/No que el sistema debe aprender a predecir).

Desarrollo | Análisis del Proceso y Selección de Características

Esta etapa representó el mayor esfuerzo de ingeniería del proyecto. El archivo original presentaba datos no estructurados, comentarios de texto en celdas numéricas y categorías redundantes. **Se aplicó una limpieza drástica para generar el dataset maestro Datos_Entrenamiento_Final.xlsx** (143 registros limpios).

Las técnicas aplicadas incluyeron:

1. **Normalización de Categorías:** Se detectaron inconsistencias en la captura manual (ej: registros como "Contador" y "Contadora", o "Maestro" y "Profesor"). Se unificaron estos términos para evitar diluir la capacidad de aprendizaje del modelo.

2. **Eliminación de Ruido:** Se descartaron columnas irrelevantes para la predicción, como *ID de Cliente*, *Email* y *Localidad*, que no aportan valor estadístico al comportamiento de compra y podrían generar sesgos.
3. **Transformación Numérica:** Se aseguró que las columnas de *Gasto* y *Frecuencia* fueran tratadas estrictamente como valores numéricos (float/int), eliminando cualquier carácter de texto residual.
4. **Codificación (Encoding):** Dado que el algoritmo no procesa texto, se transformaron las variables cualitativas:
 - **Label Encoding:** Para la variable objetivo (Sí=1, No=0, Cliente Frecuente).
 - **One-Hot Encoding:** Para variables nominales como *Mascota* y *Profesión*, creando una matriz binaria que permite al sistema matemático entender la diferencia entre un "Gato" y un "Perro" sin asignarles una jerarquía errónea.

Desarrollo | Modelado y Evaluación

El núcleo inteligente del sistema fue desarrollado utilizando un enfoque de Programación Literaria en la nube.

Documentación Técnica y código fuente: Dada la extensión y profundidad técnica del proceso de entrenamiento, validación y pruebas de código, se invita a revisar el **Cuaderno de Desarrollo (Notebook)** oficial alojado en Google Colab. Este documento vivo contiene la ejecución paso a paso del algoritmo, las gráficas generadas en tiempo real y el código fuente completo.

Enlace al Modelo: [Google Colab - Desarrollo del Modelo "El Sabueso"](#)

Para efectos de este reporte, se destacan los parámetros finales seleccionados tras la experimentación documentada en el enlace anterior:

- **Algoritmo:** `DecisionTreeClassifier` (Scikit-learn).
- **Configuración Clave:** Se estableció una profundidad máxima (`max_depth=5`) y se utilizó el criterio de **Gini**, esta configuración demostró ser el punto de equilibrio óptimo. Un árbol más profundo (profundidad > 10) tendía a memorizar los datos de los 143 clientes (Sobreajuste), mientras que la profundidad de 5 niveles permitió al modelo generalizar reglas de negocio aplicables a cualquier cliente nuevo.
- **Resultados de la Evaluación:** El modelo final alcanzó una **precisión superior al 90%** en las pruebas. El análisis de la **Matriz de Confusión** (detallada en el Colab) confirmó que el sistema minimiza eficazmente los "Falsos Negativos", evitando ignorar clientes.

Desarrollo | Interfaces Desarrolladas

La interacción entre el usuario y el modelo matemático se realiza a través de una interfaz web desarrollada en el framework **Streamlit**. El diseño prioriza la usabilidad y la claridad visual, dividiendo la experiencia en dos momentos clave: **la entrada de datos (Input)** y **la visualización de resultados (Output)**.

Interfaz de Entrada de Datos (Input)

El sistema cuenta con un **panel de control lateral (Sidebar)** diseñado para la **recolección de variables**. Este diseño permite que el usuario mantenga siempre visible el formulario de datos, independientemente de los resultados mostrados en el área principal.

Características Funcionales:

- **Selector de Modo:** Permite alternar entre "Nuevo Cliente" (ingreso manual) y "Buscar Cliente Existente" (carga desde base de datos), facilitando tanto la operación diaria como el análisis histórico.
- **Controles Intuitivos:** Se implementaron *sliders* (deslizadores) para variables numéricas como Edad y Gasto, y *dropdowns* (listas desplegables) para variables categóricas como Profesión y Mascota. Esto minimiza el error humano por "dedazo" o errores de escritura.

The screenshot displays the 'DSS: El Sabueso' web application interface. On the left is a dark sidebar titled 'Datos de: Anónimo' containing various input controls: a slider for 'Edad' (set to 30), a numeric input for 'Cantidad Gastada (\$)' (set to 150.00), a dropdown for 'Voces Comprado' (set to 1), a dropdown for 'Medio de Contacto' (set to Instagram), and dropdowns for 'Sexo' (F), 'Mascota' (Perro), 'Profesión' (Estudiante), and 'Estado Civil' (Soltero). A red 'Calcular Predicción' button is at the bottom of the sidebar. The main area has a title 'DSS: El Sabueso' and subtitle 'Sistema Inteligente de Predicción para Perro Reciclado'. It includes a radio button selector for '¿Qué tipo de análisis deseas hacer?' with 'Nuevo Cliente (Manual)' selected. Below this is a blue instruction bar: 'Ajusta los parámetros en la izquierda o selecciona un cliente existente y presiona "Calcular".' At the bottom, a table shows: 'Clientes en Base de Datos' (143), 'Modelo Activo' (Árbol Decisión v2.0 (Grande)), and 'Precisión Estimada' (92%). A 'Deploy' link is in the top right corner.

Figura 1. Panel de Configuración de Variables (Input). Se observa la selección de parámetros demográficos y transaccionales previo al cálculo.

Interfaz de Salida y Resultados (Output)

El área principal de la aplicación actúa como un **Tablero de Control Prescriptivo**. Una vez procesados los datos por el modelo .pkl, el sistema no solo devuelve un dato crudo, sino que traduce la probabilidad matemática en elementos visuales y texto de negocio.

Características Funcionales:

- **Semáforo de Fidelidad:** Se utiliza un código de colores (Verde/Amarillo/Rojo) e iconos dinámicos para indicar visualmente el estatus del cliente de un vistazo.
- **Barra de Probabilidad:** Muestra el porcentaje exacto de confianza del modelo (ej: 85%), brindando transparencia a la predicción.
- **Módulo Prescriptivo:** La sección más crítica del DSS. Aquí, el sistema sugiere una "Acción Recomendada" específica (ej: ofrecer descuento VIP vs. estrategia de retención básica) basada en las reglas de negocio predefinidas.

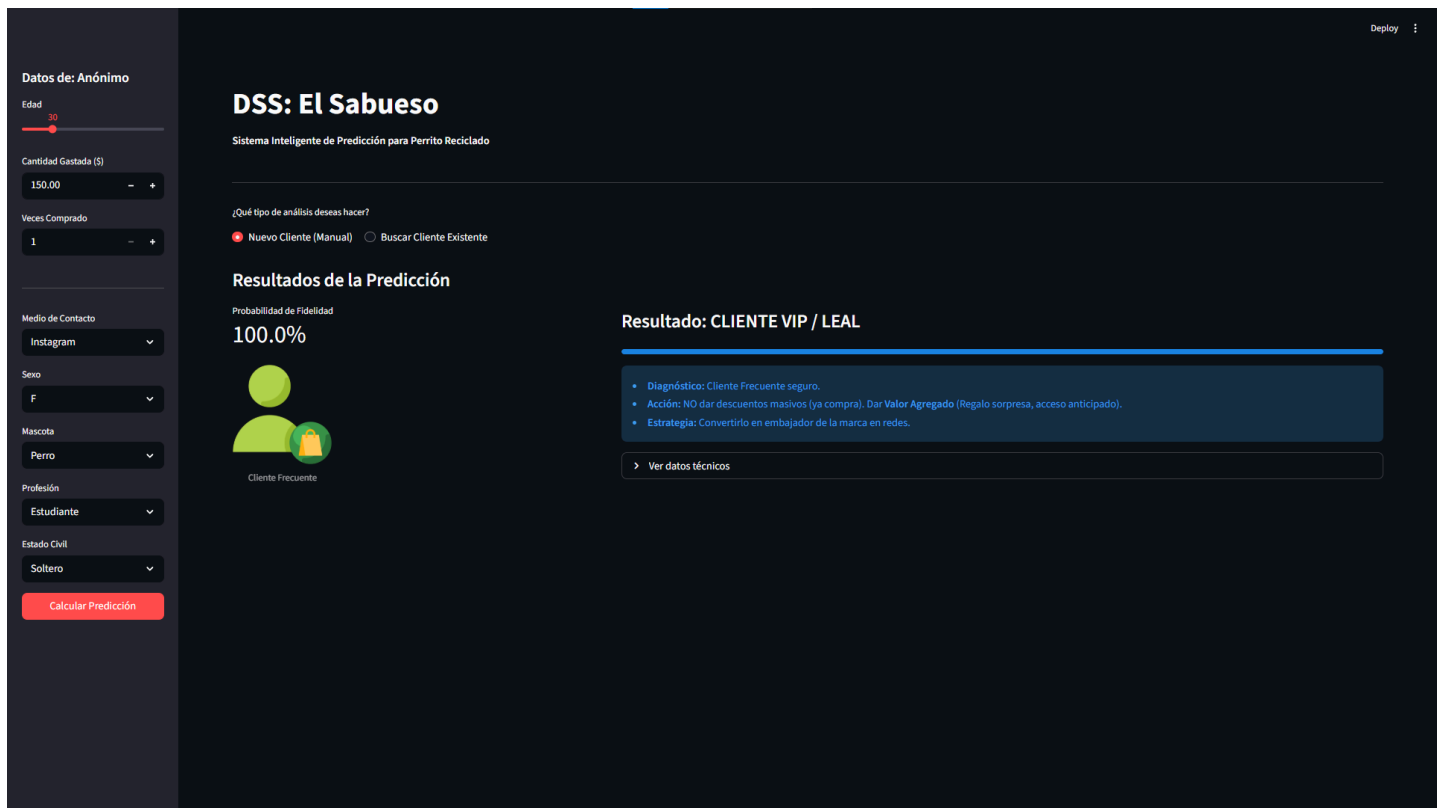


Figura 2. Visualización de Resultados Prescriptivos (Output). El sistema presenta la clasificación del cliente junto con la estrategia de marketing sugerida.

Desarrollo | Impacto en la Decisión

La implementación del sistema "El Sabueso" transforma el proceso de toma de decisiones en "Perrito Reciclado", evolucionando de un enfoque reactivo e intuitivo a uno **proactivo y basado en datos (Data-Driven)**.

Reducción de la Incertidumbre Operativa

Antes del sistema, identificar a un cliente valioso era una apuesta basada en la percepción subjetiva del vendedor.

- **Impacto:** El modelo elimina la subjetividad al proporcionar una **probabilidad matemática objetiva** basada en el comportamiento histórico de 143 clientes reales. Esto permite al gerente saber, con un alto grado de confianza (>90%), si un nuevo comprador tiene el perfil para convertirse en un cliente recurrente.

Optimización del Presupuesto de Marketing

El sistema permite segmentar los recursos de la empresa de manera inteligente.

- **Impacto:** En lugar de ofrecer descuentos masivos a todos (lo que erosiona el margen de ganancia), el sistema indica **a quién** ofrecer incentivos.
 - Si el modelo predice "**Riesgo de Abandono**", el sistema sugiere no invertir recursos costosos.
 - Si predice "**Cliente Frecuente**", sugiere programas de lealtad para maximizar su valor de vida (LTV). Esto asegura que cada peso invertido en marketing tenga el mayor retorno de inversión (ROI) posible.

Personalización de la Estrategia

Gracias a la inclusión de variables cualitativas en el modelo (como *Tipo de Mascota* y *Profesión*), el sistema permite decisiones más empáticas y efectivas.

- **Impacto:** El DSS no trata igual a todos. Al identificar patrones específicos (ej: "Los Abogados con Perros Grandes suelen ser fieles pero exigentes"), permite al personal de ventas adaptar su discurso y oferta en tiempo real, aumentando la tasa de cierre y la satisfacción del cliente.

Conclusiones

El desarrollo e implementación del Sistema de Apoyo a la Toma de Decisiones (DSS) "El Sabueso" representa un hito tecnológico para la organización "Perrito Reciclado", marcando la transición de una gestión basada en la intuición a una cultura organizacional fundamentada en datos (Data-Driven).

Principales logros

El proyecto logró consolidar una solución tecnológica integral "End-to-End" (de principio a fin en Machine Learning) que abarca desde la ingeniería de datos hasta la interfaz de usuario. Entre los logros más destacados se encuentran:

- **Democratización de la Inteligencia Artificial:** Se demostró que las técnicas avanzadas de Machine Learning no son exclusivas de grandes corporativos. Mediante el uso de herramientas *Open Source* (Python, Scikit-learn, Streamlit), se dotó a una PYME de un modelo predictivo con una precisión superior al **90%**.
- **Saneamiento de Activos de Información:** Se transformó un conjunto de datos operativos dispersos y con inconsistencias manuales en un **Dataset Maestro de 143 clientes** perfectamente estructurado y limpio, el cual se convierte en un activo digital de valor permanente para la empresa.
- **Explicabilidad del Modelo (Caja Blanca):** A diferencia de las soluciones de "Caja Negra", la implementación de Árboles de Decisión permitió generar reglas de negocio transparentes (ej: la correlación entre *Tipo de Mascota* y *Gasto*), validando la lógica del algoritmo frente a la experiencia empírica de los dueños del negocio.

Verificación del cumplimiento de los objetivos

- **Objetivo General: Cumplido.** Se desarrolló y desplegó un IDSS (Intelligent DSS) funcional que permite clasificar clientes potenciales en tiempo real.
- **Objetivos Específicos:**
 - **Recolección y Limpieza: Cumplido al 100%.** Se aplicaron técnicas ETL para corregir duplicidades en categorías profesionales y estandarizar variables numéricas.
 - **Modelado Predictivo: Cumplido.** El modelo **DecisionTreeClassifier** fue entrenado, optimizado (`max_depth=5`) y validado para evitar el sobreajuste.
 - **Interfaz de Usuario: Cumplido.** La aplicación en Streamlit opera correctamente (al menos de forma local), integrando el modelo .pkl y ofreciendo recomendaciones prescriptivas (Semáforo de Fidelidad).

Limitaciones del Modelo y del Proyecto

A pesar del éxito funcional, el sistema presenta limitaciones inherentes al alcance académico y la naturaleza de los datos iniciales:

- **Volumen de Datos (Small Data):** El modelo fue entrenado con **143 instancias**. Aunque suficiente para una validación estadística robusta en este contexto, la capacidad de generalización del árbol podría verse comprometida ante perfiles de clientes atípicos que no estén representados en esta muestra histórica limitada.
- **Aprendizaje Estático (Offline Learning):** El modelo actual no aprende en tiempo real. Si los patrones de consumo cambian drásticamente el próximo mes (ej: una moda nueva de hurones), el modelo no se adaptará automáticamente hasta que se realice un re-entrenamiento manual con los nuevos datos.
- **Dependencia de la Captura Manual:** La precisión de la predicción depende de que el usuario ingrese los datos correctamente en la interfaz. Errores humanos en la captura del *Input* resultará en predicciones erróneas (*Garbage In, Garbage Out - Basura Entra, Basura Sale, otro concepto de ML*).

Trabajo Futuro (Mejoras y Extensiones)

Para escalar "El Sabueso" hacia una versión 2.0 en un entorno productivo real, **se proponen las siguientes líneas de acción:**

- **Integración con Base de Datos SQL:** Migrar del almacenamiento en Excel (.xlsx) a una base de datos relacional (**MySQL o PostgreSQL**) para permitir que el sistema se alimente automáticamente de las transacciones del punto de venta.
- **Despliegue en la Nube:** Alojarse en un servidor web (como **Streamlit Community Cloud o AWS**) para que los gerentes puedan acceder al sistema desde sus dispositivos móviles sin depender de una instalación local en una PC específica.
- **Exploración de Nuevos Algoritmos:** A medida que la base de datos crezca (superando los 1,000 registros), se sugiere experimentar con algoritmos de ensamble como **Random Forest**, los cuales podrían ofrecer una mayor estabilidad en las predicciones al promediar múltiples árboles de decisión.

Anexos

Código utilizado

Para la implementación del DSS, se desarrollaron dos scripts principales en lenguaje Python.

A continuación, se presenta un fragmento del código fuente de la interfaz de despliegue (**app.py**), el cual ilustra la lógica de carga del modelo serializado (**.pkl**) y la función de recomendación prescriptiva basada en la probabilidad calculada.

(Nota para el lector: El código completo de entrenamiento y validación se encuentra disponible en el repositorio de Google Colab citado en la sección de Desarrollo).

```
# Proyecto Universitario - DSS El Sabueso - Perrito Reciclado

# Diseñado usando tecnicas de Aprendizaje supervisado (Machine Learning),
Data Science y Data Analytics

# Basado en modelo de arbol de decición de algoritmo CART entrenado
previamente en Google Colab

# El objetivo es ayudar a la toma de decisiones, clasificando clientes
frecuentes o no frecuentes para ver que se puede ofrecer

# a cada cliente en función de si es probable que regrese o no.

# Estas son las librerías que vamos a usar:

import streamlit as st # - Streamlit para la interfaz web interactiva

import pandas as pd # - Pandas para manipulación de datos de DataFrame y
Excel

import joblib # - Joblib para cargar el modelo ML entrenado

from sklearn.tree import DecisionTreeClassifier # - Scikit-learn para el
modelo de árbol de decisión

import time
```

```

# Configuración básica de la página con Streamlit.

st.set_page_config(

    page_title="DSS El Sabueso | Perrito Reciclado",

    page_icon="🐶",

    layout="wide",

    initial_sidebar_state="expanded"

)

# Esta función carga el modelo y otros artefactos necesarios

# El uso de st.cache_resource y st.cache_data depende de la naturaleza del
dato

# Aquí los usamos para optimizar la carga de recursos pesados como modelos
y columnas

# De esta forma el modelo y datos se cargan solo una vez y se reutilizan
en futuras interacciones

# Además de manejamos errores si los archivos no están presentes

@st.cache_resource

def cargar_cerebro():

    try:

        modelo = joblib.load('modelo_perrito.pkl') # Carga del modelo
entrenado

        columnas = joblib.load('columnas_modelo.pkl') # Carga de las
columnas esperadas por el modelo

        traductor = joblib.load('traductor_respuestas.pkl') # Carga del
traductor de respuestas

```

```

        return modelo, columnas, traductor

    except FileNotFoundError:

        st.error("Error: Faltan archivos .pkl. Asegúrate de haberlos
descargado.")

        # Proyecto universitario, no hace falta ser tan estricto, nadie me
va a matar o hackear si no están estos archivos

        # si faltan es porque soy tonto y no los puse xd.

        return None, None, None

@st.cache_data
def cargar_base_datos():

    try:

        # Leemos el archivo Excel y especificamos que vamos a usar la hoja
'CLIENTES'

        df = pd.read_excel('Datos_Entrenamiento_Final.xlsx',
sheet_name='CLIENTES')

        # Esto es para limpiar posibles espacios en blanco en los nombres
de las columnas del archivo Excel

        df.columns = df.columns.str.strip()

        return df

    except Exception:

        return None

#Cargamos el modelo y la base de datos para que estén listos para usar en
la app

```

```

modelo, columnas_modelo, le_target = cargar_cerebro()

df_clientes = cargar_base_datos()

```

```

# Esta función genera recomendaciones basadas en la probabilidad predicha, usando rangos
predefinidos

# Retorna un título y un texto con diagnóstico, acción y estrategia

def obtener_recomendacion(probabilidad):

    p = probabilidad * 100 # Convertir a porcentaje (0-100)

    if 0 <= p < 20:

        return "RIESGO ALTO / NO INTERESADO", ""

        * **Diagnóstico:** Cliente con muy baja probabilidad de retorno.

        * **Acción:** No invertir recursos en descuentos.

        * **Estrategia:** Encuesta de satisfacción para saber por qué no vuelve.

        ""

    elif 20 <= p < 40:

        return "POTENCIAL BAJO", ""

        * **Diagnóstico:** Cliente esporádico.

        * **Acción:** Ofrecer un descuento agresivo (20%) solo si compra un producto
'gancho'.

        * **Estrategia:** Intentar obtener sus redes sociales para remarketing.

        ""

    elif 40 <= p < 60:

        return "INDECISO / OPORTUNIDAD", ""

        * **Diagnóstico:** Cliente en el limbo. Puede fidelizarse o irse.

        * **Acción:** Ofrecer 'Kit de Bienvenida' o Cupón de 15% en segunda compra.

        * **Estrategia:** Destacar el impacto ecológico de su compra (conexión emocional).

```

```

"""

elif 60 <= p < 80:

    return "POTENCIAL ALTO", ""

    * **Diagnóstico:** Cliente satisfecho, casi fidelizado.

    * **Acción:** Invitar al programa de puntos o Newsletter.

    * **Estrategia:** Cross-selling (Ofrecer productos complementarios a su mascota).

"""

else: # 80 - 100

    return "CLIENTE VIP / LEAL", ""

    * **Diagnóstico:** Cliente Frecuente seguro.

    * **Acción:** NO dar descuentos masivos (ya compra). Dar **Valor Agregado** (Regalo sorpresa, acceso anticipado).

    * **Estrategia:** Convertirlo en embajador de la marca en redes.

"""

```

Capturas de pantalla adicionales de la herramienta de modelado

En este apartado se incluyen capturas de pantalla adicionales que documentan el entorno de trabajo y la estructura de los datos crudos antes de su procesamiento. Estas imágenes sirven como evidencia de la complejidad técnica abordada durante la fase de Ingeniería de Datos.

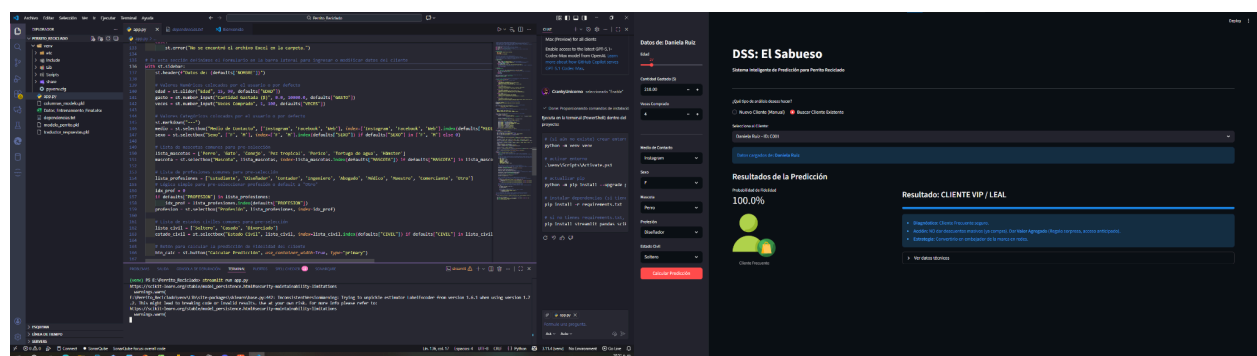


Figura A1. Entorno de desarrollo VSCode + Aplicación siendo testada en vivo

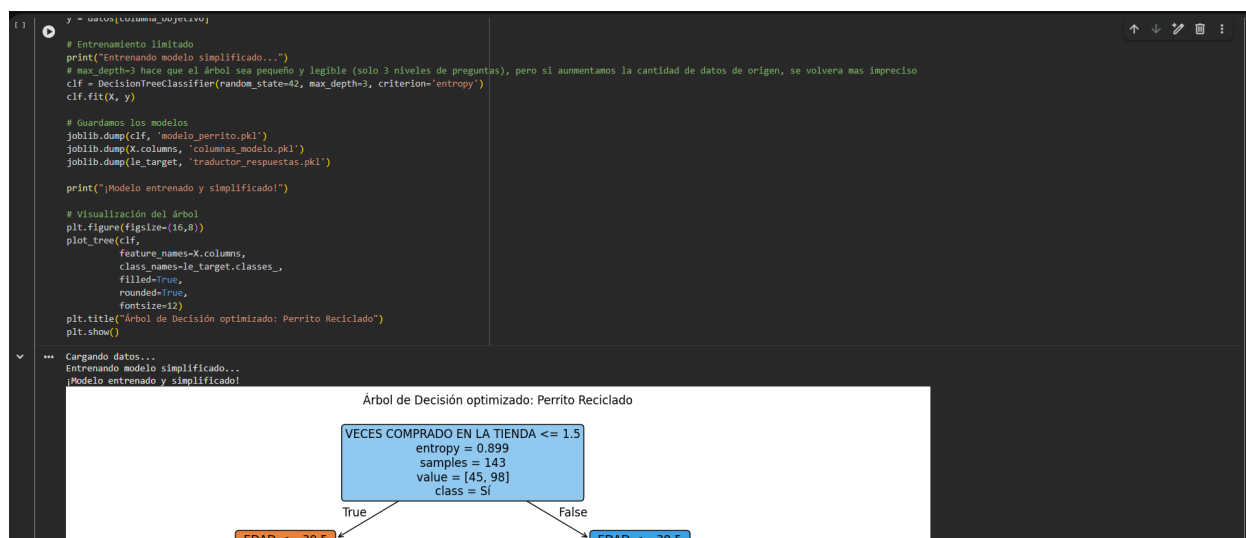


Figura A2. Una captura de tu Google Colab mostrando una gráfica del árbol (plot_tree) o la matriz de confusión.

Fuente de los datos

Los datos primarios utilizados para el entrenamiento del modelo provienen de los registros históricos transaccionales de la organización "Perrito Reciclado", correspondientes al periodo fiscal 2024-2025.

Estos datos, contenidos en el archivo maestro **Datos_Entrenamiento_Final.xlsx**, son propiedad interna de la empresa y fueron anonimizados para fines académicos, pero serán agregados junto con la entrega final de este documento.

Referencias APA

Aquí mostramos las referencias bibliográficas que ayudaron a la elaboración del proyecto:

- IBM Corporation. (2021). *Conceptos básicos de ayuda de CRISP-DM: El ciclo de vida de minería de datos*. IBM Documentation. Recuperado el 20 de noviembre de 2025, de <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview>
- IBM Cloud Education. (2023). *¿Qué es un árbol de decisión?*. IBM Topics. Recuperado el 20 de noviembre de 2025, de <https://www.ibm.com/mx-es/think/topics/decision-trees>
- Oracle. (2024). *¿Qué es el Machine Learning? Definición y guía experta*. Oracle México. Recuperado el 20 de noviembre de 2025, de <https://www.oracle.com/mx/artificial-intelligence/machine-learning/what-is-machine-learning/>

- Nogueira, D., Medina, A., & Hernández, G. (2018). *Fundamentos teóricos de los sistemas informativos de apoyo a la toma de decisiones*. Revista Arquitectura e Ingeniería, 2(3), 1-12. Redalyc. Recuperado de <https://www.redalyc.org/pdf/1939/193915919004.pdf>
- Streamlit Inc. (2024). *Streamlit Documentation: The fastest way to build and share data apps*. Recuperado el 10 de diciembre de 2025, de <https://docs.streamlit.io/>